

项目与答辩手册

店巡 Agent | 逐光队 | 2026-09-13

设备恢复不等于商品安全。事件只有在证据闭环后才能关闭。

项目介绍

店巡 Agent 面向需要受控执行与独立验收的实体业务流程，以连锁便利店冷柜失温为首个验证场景。它将设备、商品批次、停售、审批和维修事实关联到同一事件，解决“设备修好，但商品尚未满足放行条件”的协同问题。

系统由主控、巡检、诊断、执行、审计五个业务 Agent 协作，六个 P0 Skill 承载可复用能力，十二个有状态 MCP 工具连接本地设备、库存、审批和工单适配器。发现异常后先遏制，维修和商品处置按策略审批；Auditor 独立重查，IncidentService 判断业务终态，Executor 不能自证关闭。

工程实现包含事务、版本冲突控制、幂等、输出恢复、有限重试、等待唤醒与人工升级。知识候选经审核和脱敏后才发布，不自动修改业务策略。

目前六个合成冷链场景可复现，外部设备、人员和维修由有状态替身驱动。真实 AgentTeams、PolarDB、企业系统与门店收益仍需目标环境验证。本地测试不调用大模型，不将场景通过率外推为生产准确率。后续以合作方试点建立误派工单、遏制时间、证据完整率和处置成本基线，再验证复用价值。

使用这份手册

现场速查、架构与契约、恢复与证据、演示操作、逐页讲稿和评委问答合在同一份文件。正文取自现行 Markdown，数字取自事实源；后续更新源文档后重新导出。

代码与本地回归已有证据；真实 AgentTeams、PolarDB、企业接口和门店收益仍待验收。讲稿中的 VeriAgent 是决赛工作标题，正式作品名仍为店巡 Agent。

现场速查 架构 证据 演示 讲稿 问答 待办 版本来源

01 现场速查

先明确场景、正确终态和证据范围。

项目	当前可使用的口径
作品 / 队伍	店巡 Agent / 逐光
角色 / 契约	5 个业务角色、6 个 P0 Skill、12 个 P0 MCP；3 个知识工具可选
完整测试	134 项发现，132 通过，2 项 PolarDB 条件跳过
记录环境	2026-09-13；Windows / Python 3.12.13 / 本地 SQLite
模型	目标配置 qwen3.5-plus；本地评测不调用大模型

六场景的正确结果

场景	正确的固定终态
A 压缩机故障	CLOSED
B 传感器误报	CLOSED；受控解除前后分别核验
C 柜门未关	CLOSED；当前 Demo 仍配置工单
D 审批超时	CONTAINED / WAITING_EXTERNAL
E 设备恢复但商品不安全	CONTAINED / WAITING_APPROVAL
F 工单查询 partial	reopened / CONTAINED / EXECUTE / BLOCKED（本地 Adapter）

优先演示 A，再展示 E，F 作为失败处理备用。展示解除停售前两次核验时使用 B。动画、配置、工单完成或设备回温，都不能替代真实平台记录或商品安全验收。

02 架构与协作

一个业务核心，两种接入方式；五个业务角色分别承担责任。



身份	职责	权限边界
Framework Manager	接收外部任务、选择 Team、汇总	框架实体，不计入五个业务 Agent，不直接执行领域动作
Orchestrator	开事件、委派、协调阶段与受控 reopen	不冒充其他 Worker，不批准处置或自报业务成功
Sentry	检测、数据质量与遏制请求	只读；停售交给 Executor
Diagnoser	批次暴露建议、根因假设与证据缺口	只读；建议不直接改变库存
Executor	停售、申请审批、工单与获批处置	不能自批、自验、自行关闭事件
Auditor	独立重查、release guard、最终核验与复盘	不直接执行受控库存写，不用 Executor 的一句完成代替事实
Human	独立审批、人工证据；另可配置运维身份	不属于五个 Agent；运维 Token 不注入模型，也不能领取 Worker 任务
ScenarioEngine	固定场景中的合成审批与设备变化	仅为本地测试替身，不是真实员工或平台身份

业务阶段与运行步骤

领域阶段	runtime 协调步骤	结果
DETECT_CONTAIN	DETECT / Sentry → CONTAIN / Executor	发现并先遏制受影响商品
DIAGNOSE_DECIDE	DIAGNOSE_DECIDE / Diagnoser	关联根因和逐批次风险建议
EXECUTE	EXECUTE / Executor	按策略审批、维修及处置
VERIFY	VERIFY / Auditor → RELEASE / Executor → FINAL_VERIFY / Auditor	独立核验、必要的受控解禁、解禁后重查
LEARN	LEARN / Auditor	再次核验后由服务调用 IncidentService 关闭，生成复盘

03 Skill、MCP 与安全

契约、执行权限和业务前置条件共同约束动作。

Skill	当前版本	Owner	用途与边界
anomaly-detect	1.0.0	Sentry	发现异常、记录质量与遏制请求
coldchain-risk-assess	1.1.0	Diagnoser	批次暴露和处置建议，不直接放行
rootcause-drilldown	1.2.0	Diagnoser	带证据与反证的候选根因，不把相关性当因果
work-order-dispatch	1.0.0	Executor	受策略和审批约束的工单及处置
outcome-verify	1.1.0	Auditor	设备与商品分别核验，证据不全阻断
review-report	1.1.0	Auditor	复盘及待审核知识候选

5 个 P0 查询

query_device_context、query_inventory_batches、query_sales_holds、query_workorder、query_approval

7 个 P0 动作

apply_sales_hold、release_sales_hold、apply_batch_disposition、create_workorder、create_approval、decide_approval、record_manual_evidence

3 个可选知识工具

search_knowledge、create_knowledge_candidate、review_knowledge_candidate

响应与失败处理

当前 ToolEnvelope 的字段为 ok、data、error、request_id、source、source_ts、partial、audit_ref，见 Schema；没有另一套 status/evidence/meta 顶层字段。HTTP 200 只表示传输完成，必须核对 ok、partial 和 error。INVALID_ARGUMENT、FORBIDDEN 不盲目重试；APPROVAL_REQUIRED 进入原审批等待；APPROVAL_INVALID 重查；INVALID_STATE 重读状态。审批 timeout 与人工 rejected 分开，都不能当批准。

查询不完整不能当作成功。Executor 不决定审批；Human 凭证不注入模型。解除停售需要对应批准与新鲜的 Auditor release_guard，随后还要重查。幂等与本地事务不能撤销已经发生的真实外部副作用。

04 运行与故障恢复

服务端执行截止与预算，Worker 的完成声明不能推进业务终态。

uv run dianxun-mcp 在配置 DIANXUN_RUNTIME_TOKENS_JSON 后自动启动后台巡查，每 5 秒扫描一次。它不调用模型，也不等待 Agent 主动发起重派。所有 Worker 启动后及空闲期间每 10 秒调用 runtime_poll({})，登记在线状态并获取自己的 assignment、incident_id、context_version。只有 Token 配置、没有近期 poll 的实例不会作为健康候选者。

项目	当前默认值 / 行为
心跳租约	60 秒；不能续过硬截止
在线健康	最近 90 秒内有 poll；每实例最多 1 个有效任务，主控任务也计入
主控	单次 60 秒、无进展 30 秒、每次阶段交接总预算 180 秒、最多 3 次，优先换实例，否则确定性派发
巡检	单次 180 秒、无进展 90 秒、阶段总预算 900 秒
诊断 / 审计	单次 300 秒、无进展 120 秒、阶段总预算 1800 秒
执行（含应急保护）	单次 300 秒、无进展 120 秒、阶段总预算 21600 秒
失败重试	最多 3 次执行失败，5 秒指数退避、最高 60 秒，加 0–4 秒稳定抖动；失败实例冷却 30 秒
等待后重新派发	不算执行故障；新 assignment / 递增 attempt，阶段最多派发 32 次，仍受原总预算限制
审批等待	使用原审批 deadline；维修最多等待 4 小时；两者都不得超出阶段总截止和 Context TTL
告警	持久化责任角色 store_manager、15 分钟响应期限、固定去重 ID、领取和投递状态

已实现：后台巡查、主控监督、硬截止、有效进展、有限重试、健康备用与容量、等待唤醒、输出恢复、回执核验、人工升级、通知 Outbox 和受控应急汇合。恢复专项有 22 项本地回归。

通知 Outbox 尚未连接真实短信、飞书或邮件。应急停售默认关闭，仅在预授权范围启用。未知回执、预算耗尽和不可重试故障转人工；不得刷新预算、伪造成功检查点或恢复旧租约。

05 评测结果与证据

完整回归记录：2026-09-13。

指标	结果
test_*.py 文件	20
unittest 发现数	134
通过	132
跳过	2 (需要外部 PolarDB 测试实例)
P0 MCP registry/调用路径映射	12/12
正式行/分支覆盖率报告	未生成
协调上下文并发	双实例 stale writer、双线程超时重派已验证；多进程/高争用压测待补

六场景确定性评测

6/6 场景通过；Top-1、Top-3 均为 6/6；Evidence 45/45；Trace 26/26；测试定义的安全违规 0 起。

消融实验：按实际结果解释

设置	实际观察	解释边界
full	6/6 验收通过	本系统的固定合成样本
no_auditor	5/6 停于 VERIFY/BLOCKED；0 不安全放行	缺少独立验证时保持遏制，其他安全门仍然生效
single_agent	6 次写入被拒	验证本系统单身份的权限边界
rule_only	Top-1 4/6；2 次错派	替换诊断排序，保留下游防线

这些结果不证明模型效果、生产准确率或经营收益，也不支持“去掉 Auditor 导致 5 次错误放行”。真实 AgentTeams、PolarDB/OSS、企业接口、容器与门店验证分别取证。

06 演示与录屏

本地演示开场说明：设备、维修和审批为合成数据，业务状态实际写入本地数据库。

操作	口播	需要展示的证据
展示A初始状态和事件编号	同一事件关联设备、受影响批次、审批和工单。	incident_id、批次、设备、初始状态
展示遏制和审批	系统先停售；维修和处置按策略申请批准。	hold状态、审批对象与时间、动作结果
展示A独立验证和关闭	完成动作后由Auditor重新查询，再由领域服务判断是否关闭。	独立查询、处置结果、最终CLOSED、审计
切换E	这里设备已经恢复，但商品仍不满足处置条件，事件保持遏制。	设备恢复、批次仍不安全、CONTAINED
按需切换F	查询不完整不等于成功。本地流程回到处置阶段并阻塞，保持停售。	partial字段、result=reopened、CONTAINED/EXECUTE/BLOCKED

独立临时数据库复现 A / E / F

```
$finalsRunName = 'veriagent-rehearsal-' + [guid]::NewGuid().ToString('N')
$finalsDemoDir = Join-Path ([System.IO.Path]::GetTempPath()) $finalsRunName
New-Item -ItemType Directory -Path $finalsDemoDir -ErrorAction Stop | Out-Null
$finalsScenarios = @(
    'coldchain-compressor-failure',
    'coldchain-device-recovered-goods-unsafe',
    'coldchain-workorder-query-partial'
)
foreach ($finalsScenario in $finalsScenarios) {
    uv run dianxun demo-run "demo/state/scenarios/$finalsScenario.json" `
        --db (Join-Path $finalsDemoDir "$finalsScenario.db") `
        --output (Join-Path $finalsDemoDir "$finalsScenario.json")
    if ($LASTEXITCODE -ne 0) { throw "演练失败: $finalsScenario" }
}
Write-Output "本次演练目录: $finalsDemoDir"
```

A 为 CLOSED；E 保持 CONTAINED / WAITING_APPROVAL；F 为本地 reopened / CONTAINED / EXECUTE / BLOCKED。展示受控解禁用 B；平台录像保留真实委派、身份、租约、检查点、回执与独立核验，录屏须脱敏。

07 逐页讲稿 01-04

对应 12 页决赛工作稿。正式陈述、演示与问答时长依组委会通知。

P1 | 项目介绍

各位评委好，我们是逐光队。VeriAgent 面向需要受控执行和独立验收的实体业务流程。我们以冷柜失温作为第一个验证场景，解决一个具体问题：冷柜修好了，柜里的商品是否就能继续售卖？我们的系统要求设备、商品和处置证据分别完成核验，才允许关闭事件。

P2 | 谁需要这个系统

总部运营、区域督导和店长现在往往需要在温度告警、群消息、工单和审批之间确认进展。维修回执只能说明维修动作，温度恢复只能说明设备状态。我们将这些事实关联到同一个事件，并把“商品是否可以放行”设为独立验收条件。高风险处置先审批，执行者的回执不能替代验收。

P3 | 实际架构

业务状态由 IncidentService 管理，Policy 约束权限和审批，StateStore 提供事务与持久化。我们提供本地确定性验证入口和 AgentTeams Worker 运行接口，两者接入同一业务核心。当前本地事务和HTTP路径已验证；真实 AgentTeams 动态协同、人员审批与外部系统接入，需要目标环境证据。不会将配置文件当作运行完成证明。

P4 | 五个角色

Orchestrator 协调阶段，Sentry 发现异常，Diagnoser 提出证据关联假设，Executor 在权限和审批范围内执行，Auditor 独立重查。框架 Manager 不计入这五个业务角色。角色设计的重点是动作权限和验收责任可追溯，不能让执行者通过一句“完成”绕过领域门禁。

VeriAgent 为讲稿工作标题；正式名称、PPT 版本和现场时长在交付时统一冻结。

07 逐页讲稿 05-08

对应 12 页决赛工作稿。正式陈述、演示与问答时长依组委会通知。

P5 | 一条闭环

发现失温后先停售和隔离，避免继续暴露风险；随后评估各批次的超温暴露并提出诊断假设。维修和商品处置按策略申请批准。执行结束后，Auditor 查询设备、商品、停售和审批等事实，满足条件才关闭。复盘生成知识候选，经过审核和脱敏才能发布。

P6 | 正常和失败分支

我们验证了六个合成场景。前三个分别处理设备故障、传感器疑点和柜门未关；后三个处理审批超时、设备恢复但商品仍不安全、工单查询不完整。在失败场景中，“保持遏制”本身就是正确结果，不能为了演示一条绿线而强行关闭。本地工单查询不完整时会回到处置阶段并阻塞，等待补齐证据。

P7 | Skill工程

六个 P0 Skill 都有输入输出 Schema、调用边界、失败示例和版本记录。以 coldchain-risk-assess 为例，它按批次评估超温暴露并提出建议，不直接写库存或放行。Registry 用名称、版本和摘要定位制品，Worker包固定来源，Trace记录实际使用的Skill版本。平台发现和调用这些Skill的过程还要在真实运行时核验。

P8 | 安全与恢复

写操作依次经过角色权限、策略审批、幂等和审计。解除停售必须获得相应批准，并通过Auditor核验。商品报损不能靠软件回滚恢复，因此审批在前。HTTP运行接口在查询不完整时保持遏制并重查；取得完整的失败核验后，才允许按权限开始新的处置轮次。真实维修取消和对账需要企业系统适配。

07 逐页讲稿 09-12

对应 12 页决赛工作稿。正式陈述、演示与问答时长依组委会通知。

P9 | 验证结果

在本地临时 SQLite 和合成数据环境下，六个场景全部通过，45条证据记录和26个适用阶段Trace完整，未出现测试定义中的五类安全违规。完整测试的最新命令、日期及通过/跳过数见测试覆盖矩阵，演讲前按冻结版本读取。这些是有限样本下的工程结果，不代表生产准确率，也不是模型效果评测；本地评测不调用大模型。

P10 | 已完成的改进

我们根据反馈聚焦冷链闭环，补强了商品当前安全检查、独立验收和权限约束。最新修复还覆盖三个容易在现场暴露的问题：失败操作不能留下部分写入；响应丢失后可以取回原输出；完整核验失败后可以按权限重新处置。相应本地回归已经通过，真实平台恢复还需单独取证。

P11 | 如何复用

可以复用的是职责分离、证据关联、状态管理和受控验收方式。迁移到餐饮配送时，要替换交接批次、暴露规则和WMS接口；迁移到设备检修时，要替换诊断Skill、检修动作和复产条件。我们不承诺只换配置就完成所有行业适配，每个新领域都要重新验证。

P12 | 交付和下一步

目前我们提供可复核的业务核心、六场景验证、Skill与MCP契约以及Worker制品。下一步重点是取得真实AgentTeams协作证据，并与冷链合作方对接设备、库存和审批接口，建立真实试点基线。VeriAgent坚持的完成条件是：设备恢复不等于商品安全，事件只有在证据闭环后才能关闭。谢谢各位评委。

08 评委问答 1/2

先说明当前实现，再给证据与适用边界。

为什么需要多Agent，单Agent加权限工具不行吗？

单Agent也能使用权限和状态机工具。我们选择分离角色，是为了明确读取、执行和验收责任，并在运行接口上约束角色、scope和租约。价值要通过可追溯协作和失败处理来证明，不能仅用Agent数量证明。当前单身份消融验证的是本系统Policy的拒动边界，不能外推为所有单Agent方案都更差。

与普通工单系统有什么区别？

普通工单也可以配置审批和复验。我们的重点是将设备、商品、停售与处置事实关联到同一个事件，由独立核验条件决定能否关闭，并为工具失败、输出丢失和重新处置提供运行接口。实际优劣需要与合作方现有流程建立同口径基线比较。

哪些部分是大模型做的？

当前本地六场景评测不调用大模型，诊断是证据关联的确定性逻辑。AgentTeams目标部署声明了模型和Worker运行方式，但真实模型委派、工具选择、成本和效果须用目标平台日志证明。不能把本地6/6说成大模型准确率。

Auditor自己判断错了怎么办？

Auditor不能只复述Executor结果，需要重新查询多个事实，数据不全则阻断。领域服务还检查当前商品状态、审批范围和版本。但独立查询也不能保证传感器和人工输入绝对正确，所以真实部署需要数据质量校验、独立测量和业务负责人批准的规则。

如何判定食品已经变质？

当前不做真实食品变质检测。实现按批次计算超温度分钟，并依据比赛示例策略给出处置建议。真实部署必须由专业方提供适用商品的阈值、验证数据和处置规则，不能拿合成阈值直接决定食品放行。

断网、超时、重复请求会怎样？

证据缺失时保持遏制；有幂等键和事务约束，已完成的阶段输出随checkpoint保存。HTTP运行接口开始新处置轮次需要完整失败核验、正确角色和版本，旧租约不能继续写。本地Adapter的F场景会记录reopened并回到EXECUTE/BLOCKED，不能把这个结果当作HTTP运行接口已重执行。本地HTTP和恢复回归已验证；现场平台的进程重启和网络故障需单独演练。

能支撑512设备、500ms或多行业吗？

目前不作这些性能与规模承诺。512设备是旧展示中的模拟网络，当前可复核基线是六个冷链场景。迁移需要替换领域契约、策略与接口并重建验证集。性能应在明确硬件、模型、负载和外部接口后测量分位延迟与失败率。

08 评委问答 2/2

先说明当前实现，再给证据与适用边界。

商业价值如何量化？

建议试点记录人工串联时间、误派工单、异常到遏制时间、证据完整率、处置成本和商品损耗，并与同口径基线比较。目前没有真实经营数据，因此不承诺下降百分比或投资回收期。

有哪些开源贡献？

公开仓库提供领域核心、六个 P0 Skill 契约、MCP 接口、Worker 包、测试、演练及部署说明。需要按固定版本复现和验证；正式 Release、第三方采用和真实平台证据应分别列出，不能由源码公开推断生态已建立。

是否做了形式化验证？结构正确就能保证结果正确吗？

当前使用六个 Skill 的运行时 Schema、Policy、事务/幂等、独立核验和人工审批，没有形式化证明。结构正确不等于输入真实或模型语义正确；传感器、商品规则和真实人员仍须验证。细节见验证机制。

SQLite 是否有 WAL、乐观版本和并发回归？

独立 ContextBus 使用 WAL/expected_version；业务 SQLite 不强制 WAL，但 Incident 有版本 CAS，RuntimeContext 与领域写共用事务，嵌套失败使用 SAVEPOINT 回滚。已有真实线程和多实例回归，生产高争用与托管 PolarDB 单独验收。见一致性说明。

HTTP 延迟、重试与审批超时怎么回答？

默认 32 个连接、10 秒绝对截止、1 MiB body 上限；超限/满载分别是 413/503。runtime 有有限重试、等待和未知回执升级，没有已实测 P99 SLA 或通用熔断器。审批 timeout 不等于人工 rejected，更不能当批准。见 MCP 可靠性。

RAG、真实 IoT 与覆盖率如何界定？

当前检索使用 embedding，本地默认确定性 Hash Embedding，也支持兼容 provider；没有 BM25 hybrid/reranker 的实跑基线。知识须先审核脱敏。IoT 在本地由有状态替身驱动，轮询/订阅协议及延迟待真实平台选择；不存在已验证的 30 秒全网巡检。12/12 是 P0 工具契约/路径映射，不是行覆盖率。更完整的工程和试点边界见测试矩阵与业务差距。

09 当前待办与交付

本页为导出时快照。唯一维护入口仍是 docs/待办.md。

ID	优先级	状态	工作与完成标准
T01	P0	待实现	测量与风险建议：按时间去重/排序、检查覆盖与长缺测、区分未知；人工测温绑定批次/时间/仪器；错误对象、单样本、未来/过期证据的反例不能给出无依据放行建议
T02	P0	待实现/接入	实物与销售控制：转移接收、报损凭证、数量守恒、批次范围版本及审批适用性；POS/SKU/批次和多渠道回查对账；未接收/未知渠道不能标全部完成
T03	P0	外部待验	在隔离 AgentTeams、容器和 PostgreSQL 环境固定实际版本，执行下方故障表与身份测试；保存同任务原始记录、脱敏报告和失败复测
T04	P0	待冻结	确认正式赛事时长/地点/格式/截止；按最新实现修订 PPT 和 PDF、录制真实平台片段、彩排；代码 SHA、部署、包、讲稿、PDF 和录屏对应，保留提交回执
T05	P1	待实现/接入	人员履约：认领、无法执行、当班代理、交班、维修到场、人工接管；Outbox 映射真实值班人与渠道，投递/认领/处置分别可查
T06	P1	待试点	真实规则和基线：商品策略签批、设备/探头校准、影子模式、事件标注；比较相同权限与安全门下的人工/规则/Agent 流程
T07	P1	待验证	正式行/分支覆盖率、多进程高争用、目标 SLO、RTO/RPO、备份恢复、跨机和数据库/OSS 故障；保留环境及原始样本
T08	P2	后续候选	累积暴露、库位容量、召回/已售追溯、无需维修路径、复发治理、跨店知识和新领域适配，按试点需求选择

原待办 01 的有界恢复已完成本地实现；原待办 02 的分析与 36 项验收要求已整理，业务代码缺口仍需修复；原待办 03 的方案已制定，真实目标平台验收仍待执行。

现场需冻结正式时长、材料格式、源码与部署版本、PPT、讲稿和录屏。新手册完成不等于实际平台、全部材料或正式提交完成。

10 版本、来源与复核

保留可追溯输入，更新正文后显式导出并检查每页。

项目	本次记录
资料日期	2026-09-13
源码基线	022cfbdd0618ad1a65f14da0a0e8aa69f58f38b1
内容来源	当前工作区的现行 Markdown 与结构化事实；包含本轮文档整理
测试记录	2026-09-13；详见测试覆盖矩阵
源内容摘要	04ae2fd0a876a3ce2f43d9571ea9b4d317789fd4f8778df999a7ac30326db0c4
正式名称	逐光 / 店巡 Agent；VeriAgent 为决赛工作稿标题

权威维护位置

- 项目简介：docs/competition/项目简介.md
- 讲稿与问答：docs/competition/决赛讲稿与问答.md
- 技术契约：docs/技术说明.md
- 运行恢复：docs/operations/runtime-recovery.md
- 唯一待办：docs/待办.md
- 测试证据：docs/测试覆盖矩阵.md
- config/project-facts.json
- evidence/m4/ablation.json
- skills/registry.json
- 源码仓库：<https://github.com/XZQ/zhuguang>

维护与导出

- 更新上述现行文档，完成受影响验证后同步事实源。
- 运行 `uv run scripts/build_project_handbook.py`。
- 核对数字、来源、链接、分页与图表，重建门户以复制这份新制品。
- 发布与真实环境验收独立执行；旧复赛 PDF 保持原路径、原字节。

本手册替代三份复赛稿作为当前阅读入口。原复赛 PDF 是 2026-09-04 历史材料，其旧测试数、量化经营效果和平台已验证说法不作为当前事实。既有 PPT/PDF 与线上站点的发布版本另行核对。